第一视角人—物交互预测

完整 Pipeline 技术报告

手部姿态 · 物体 6D · 动态交互图 · RSI 优化

2026 年 11 月 13 日　单栏公开版 · 连续 Demo 更新

摘要

本文介绍第一视角行为意图预测系统的完整技术链：视频与原生时间轴整理、双手 21 点状态、物体六自由度及表面运动、坐标对齐与监督构建、动态交互图预测，以及基于验证反馈的 RSI 优化。感知模块分别支持 MediaPipe 与 FoundationPose 的 RGB-D 实测分支，以及官方手姿态与双目重建的 EgoDemo 数据分支；图预测采用 120 / 132 维实体特征、帧内注意力和可替换的 Mamba、LSTM、因果 Transformer。报告纳入可公开的真人手物、多物体 6D 与点云演示，新增同一真人视频上从 RGB、手部与 6D 到实际 LSTM 关系输出的连续演示，并从保存的逐帧数组和日志绘制覆盖、几何一致性与性能验证图。服务器已回收的扩展阶段 test micro-F1 为 LSTM / Transformer 0.938853、Mamba 0.905200；项目方确认最终全量结果约 0.93。后续 rsi_final 实际账本含 30 条记录、21 个已评分候选，本文给出可复算逐轮曲线，并将其验证成绩与独立测试结果分开。所有图表保留数据版本、输入条件和来源，覆盖从感知到预测的模块原理与实测证据。公开版不包含 EgoDemo 原始画面、记录标识或逐条数据；相关图明确使用原理示意。

目录

1 研究目标与系统概览 . . . 2

2 相关工作 . . . 2

3 原始视频、时间轴与输入条件 . . . 3

4 手部姿态估计与坐标对齐 . . . 3

5 物体 6D 位姿与表面运动建模 . . . 5

6 感知模块的指标与验证图 . . . 7

7 数据构建与版本演进 . . . 9

8 动态交互图预测方法 . . . 11

9 RSI 自动迭代优化 . . . 12

10 实验结果与版本对应 . . . 14

11 完整流程的连续 Demo 与可视化 . . . 16

12 复现与分析要求 . . . 18

13 结论 . . . 19

参考文献 . . . 19

A 公开入口与数据状态 . . . 20

B 图像来源、署名与公开版范围 . . . 20

C 复现和仍需补充的验证 . . . 20

1 研究目标与系统概览

操作行为的提前预测不仅需要知道“发生了什么动作”，还需要判断接下来由哪只手、作用于哪个物体、形成何种关系。手部接近物体可能对应拿取、稳定或即将释放；工具与工件的交互还涉及两个不同客体。单一视频类别难以表达这些结构关系。本项目将可观察的未来交互关系作为行为意图的操作性目标，以有向图统一表达主体、客体与多种并存的关系。

完整系统包括五个环节：视频与原生时间轴整理；手部及物体状态提取；视觉复核与图监督构建；实体编码和时间预测；以及基于验证反馈的 RSI 优化。系统已经历从小子集联调、自动复核、多采集冻结训练，到位姿增强和后续 RSI 搜索的连续演进。早期五段实验仅是开发过程中的一个节点，不能替代最终全量结果。

本文重点描述可实现的模块接口和演进关系，而不将收益简单归因于某一个网络。骨干、数据覆盖、监督质量和输入特征在不同阶段均发生变化。评估应先在同一冻结版本内比较，再讨论不同版本之间的工程发展。

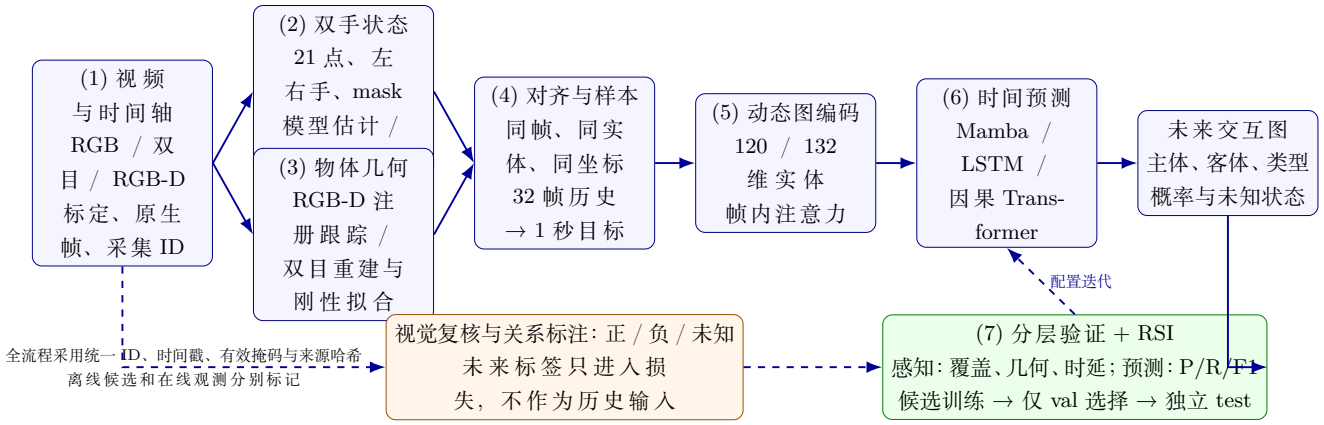


图 1 完整 pipeline 与数据流。(2) 手部和 (3) 物体分支并行，(4) 统一时间、身份与坐标，(5)(6) 学习历史到未来的交互变化，(7) 分别验证感知与预测，并驱动 RSI 配置迭代。未来标签经监督分支进入损失与评估，不进入历史特征；各分支的来源、有效 mask 和版本随数据传递。

报告范围。 本次直接读取了服务器训练配置、评估文件与三个 RSI 系列账本，并检查本地既有感知输出。项目方确认的最终全量约 0.93 与已保存的阶段评估分别标明来源；当前 rsi_final 目录的验证结果不自动当作独立测试成绩。感知演示与预测测试采用不同数据条件时分别说明，避免把模块通过率拼接成端到端精度。

2 相关工作

第一视角数据集 EPIC-KITCHENS-100 覆盖活动识别、检测与提前预测等任务 [1]；Ego4D 拓展了第一视角活动的数据范围 [2]。本文使用 EgoDemo 及其本地派生版本 [4]，预测具有显式实体引用的未来交互图，不将不同数据集和评价协议的数值直接排名。

手部状态可通过 MediaPipe Hands 等方法从图像估计 [6]，物体六自由度位姿与跟踪可参考 FoundationPose[5]。项目既有独立 RGB-D 感知演示，也有使用官方手姿态、审核二维观测和派生几何的训练线路。二者属于不同输入条件；模块演示的帧率不直接等于交互预测全系统的帧率。

Mamba 采用输入依赖的选择性状态空间机制，具有沿序列长度线性扩展的特性 [3]。本项目将其用作可替换的时间骨干，保留 LSTM 和因果 Transformer 作为对照。核心工程设计是统一实体与交互表示、部分监督学习和可回溯的自动优化流程，而非重新提出基础状态空间算子。

3 原始视频、时间轴与输入条件

完整 pipeline 首先确定每个观测对应哪个采集、相机、帧和物理坐标，再进入手部与物体分支。视频切分阶段输出短片及索引，记录来源视频、起止时间、实际帧数与帧率。需要精确边界时重新编码，避免仅按压缩流关键帧切割引入偏移。多相机和同一长视频的不同切片按采集 ID 分组，训练 / 验证 / 测试划分在滑窗之前固定。

第一视角主线保留标注版视频的原生时间戳与相机参数。Raw 版与标注版并不保证同一帧号对应同一时刻，必须通过实际长度与时间轴核对。图预测使用 32 帧历史和至少 1 秒的未来目标；这与制作视频时使用 3fps 或 10fps 回放是不同概念。

系统保留两种可追溯的感知输入条件：EgoDemo 线路使用官方手姿态、同采集双目和派生物体几何；独立 RGB-D 验证线路使用 MediaPipe 与 FoundationPose 真实推理。后者用于验证感知模块能运行、可输出什么以及耗时多少，不能直接替代前者的预测测试结果。输入无深度、无尺度或无物体模型时，也不能把另一个 RGB-D 场景的假设自动转移过去。

4 手部姿态估计与坐标对齐

4.1 从图像到双手 21 点

在线分支采用 MediaPipe Hands 的两阶段设计：先定位手掌区域，再回归手部关键点 [6]。项目封装按帧返回左右手各 21 点和有效性信息，保留腕部、四指关节与拇指拓扑。未检测到的整只手与置信字段保持 NaN，由下游 mask 明确排除。对非镜像输入按后端自拍约定交换左右手标签；不通过水平翻转原图来掩盖身份错误。

图像输出 (x, y, z_{rel}) 中的 x, y 按图像尺寸归一化，z_{rel} 是腕部相对深度，并非米制相机坐标。左右手分类分数也不是关节定位精度。实时分支和训练数据分支都保留这些语义，避免下游将两个不同坐标空间的量直接相减。

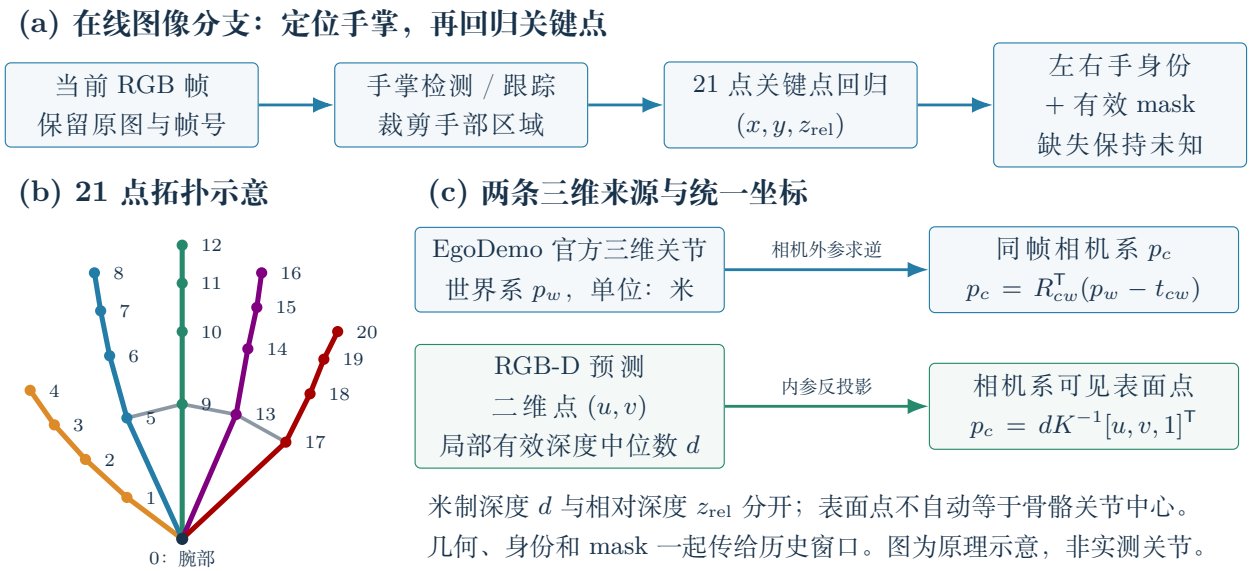


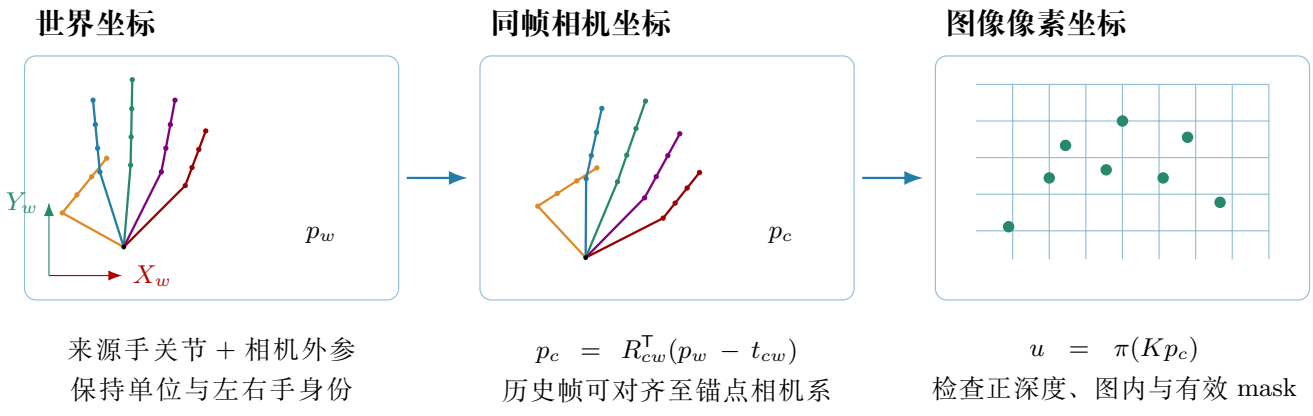
图 2 手部姿态原理图。上：手掌定位到 21 点回归的在线分支。左下：腕部与五指的 21 点拓扑。右下：官方世界系关节经相机外参转换，以及 RGB-D 二维关键点经深度反投影，两条来源分开表达。所有点与模块均为原理示意；坐标图解见图3，真实演示见图4。

4.2 官方三维姿态与 RGB-D 表面提升

EgoDemo 线路读取官方世界坐标手关节和同帧相机到世界变换。若 $T_{cw} = [R_{cw}, t_{cw}]$ 表示相机到世界，则

$$p_c = R_{cw}^{\mathsf{T}}(p_w - t_{cw}), \qquad u = \pi(K p_c). \tag{1}$$

针孔投影 π 将齐次坐标除以正深度；负深度、图外点、缺失关节分别保留标记。后续时序特征还会将历史关节转换到锚点相机系，降低头部运动造成的坐标变化。图3给出公开版的坐标变换示意。



独立原理示意；手形、点与视角不取自任何受限记录，不用于评价误差或尺度。

图 3 手部坐标对齐原理示意。世界系关节由同帧相机外参转换到相机系，再投影到图像；历史关节可进一步对齐到锚点相机系。此图独立绘制，不含 EgoDemo 原始画面或记录级坐标。真实公开手物例图见图4。

对有对齐深度的 RGB-D 输入，可在预测二维关键点附近取有效深度中位数 d，反投影为

$$p_c = dK^{-1}[u, v, 1]^{\mathsf{T}}. \tag{2}$$

HO-Cap 实现使用半径 2 像素邻域，至少 3 个有效深度，并限制 10%–90% 分位跨度不超过 0.04 米。遮挡边缘深度混杂时拒绝提升。这个点表示二维关节射线对应的可见表面，不能自动视为真实骨骼关节的三维中心。

4.3 真实同帧手物演示

图4左侧展示 DexYCB 真人持碗的手部预测与物体位姿同时输出；右侧展示 HO-Cap 四个物体的独立位姿跟踪。它们验证真实模块之间的输入输出衔接，分别保留各自场景和输入条件。工程实现可将手部 CPU 推理与物体 GPU 推理并行执行，按同一帧号等待结果齐全后再渲染。



(a) DexYCB：21 点手骨架、物体框和 XYZ 轴　　(b) HO-Cap：同一人手场景中的四物体 6D

图 4 两条真实 RGB-D 感知演示，均为既有输出。左图蓝色手骨架来自模型预测；右图从 446 帧完整视频的第 180 帧直接解码。颜色区分物体身份，坐标轴表示估计姿态。不同场景不拼接成一次运行；同帧叠加不自动证明手关节与物体已完成独立米制精度验收。

5 物体 6D 位姿与表面运动建模

5.1 六自由度与刚体变换

6D 位姿由平移三自由度和旋转三自由度组成。用物体到相机的齐次变换表示为

$$T_{oc} = \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix}, \quad R^{\mathsf{T}} R = I, \quad \det R = 1, \tag{3}$$

物体模型点 x_o 经 $x_c = Rx_o + t$ 变换后投影到图像。相机运动存在时，用 $T_{ow} = T_{cw} T_{oc}$ 统一到世界系。后续特征中使用旋转矩阵前两列的六维编码；“旋转六维编码”和“物体六自由度位姿”是两个不同概念。

5.2 RGB-D、mesh 与 FoundationPose 分支

已知几何模型的 RGB-D 分支采用 FoundationPose[5]。注册时输入当前 RGB、米制深度、相机内参、目标 mask 和对应 mesh；从姿态候选出发进行学习式细化与评分，随后使用前帧状态和当前 RGB-D 连续跟踪。项目使用真实 scorer / refiner 权重，保留原始 mesh 坐标和返回的物体到相机变换。初始 mask 与物体匹配，后续跟踪不读取未来位姿参考。

该分支的关键工程约束是单位与物体身份：uint16 毫米深度乘 0.001 后与 mesh 统一为米；网格不能任意换模型、改尺度或重心而不记录变换。碗等对称物体的朝向可能存在等价解，单看框贴合不能证明全部旋转角精确。图6展示预测 mesh、估计坐标轴与真实深度点云处于同一相机系的具体输出。

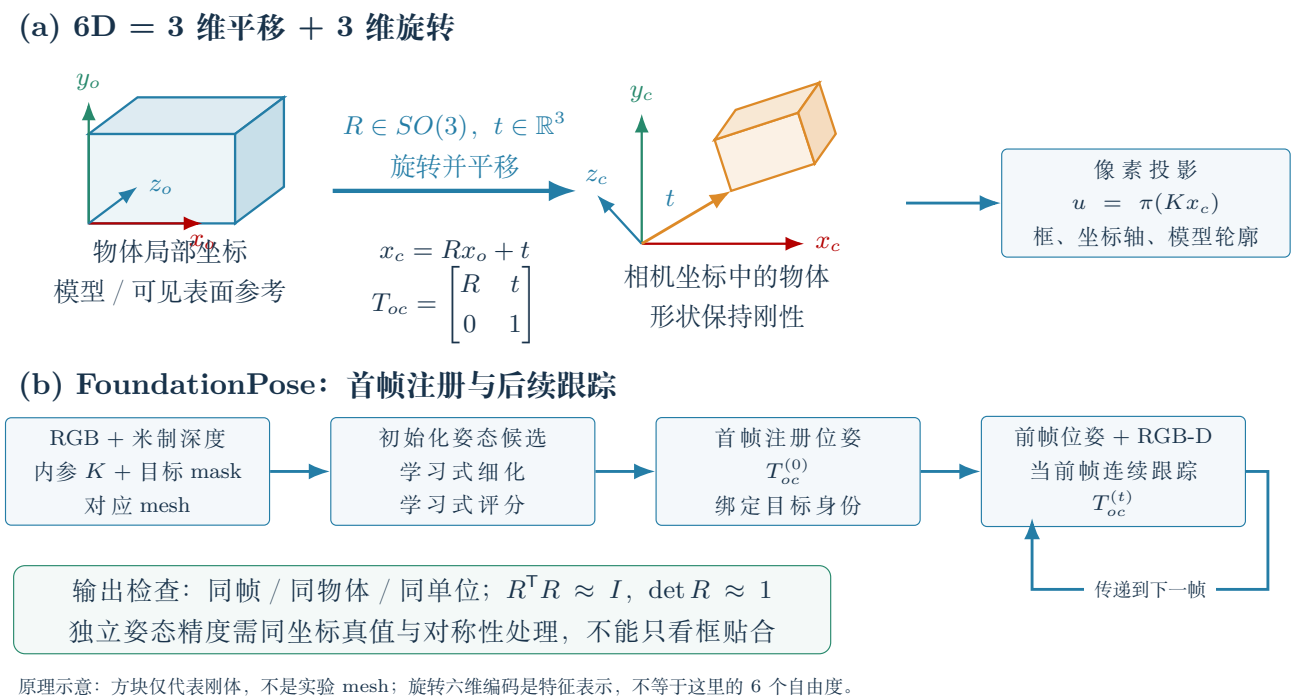


图 5 物体 6D 与 FoundationPose 原理图。上：物体点由旋转 R 和平移 t 变换到相机系，经内参投影为框、轴或轮廓。下：首帧 RGB-D、mask 与 mesh 用于姿态候选细化和评分，后续由前帧位姿与当前观测连续跟踪。图中方块是几何示意，不是实测模型；真实点云与 mesh 输出见图6。

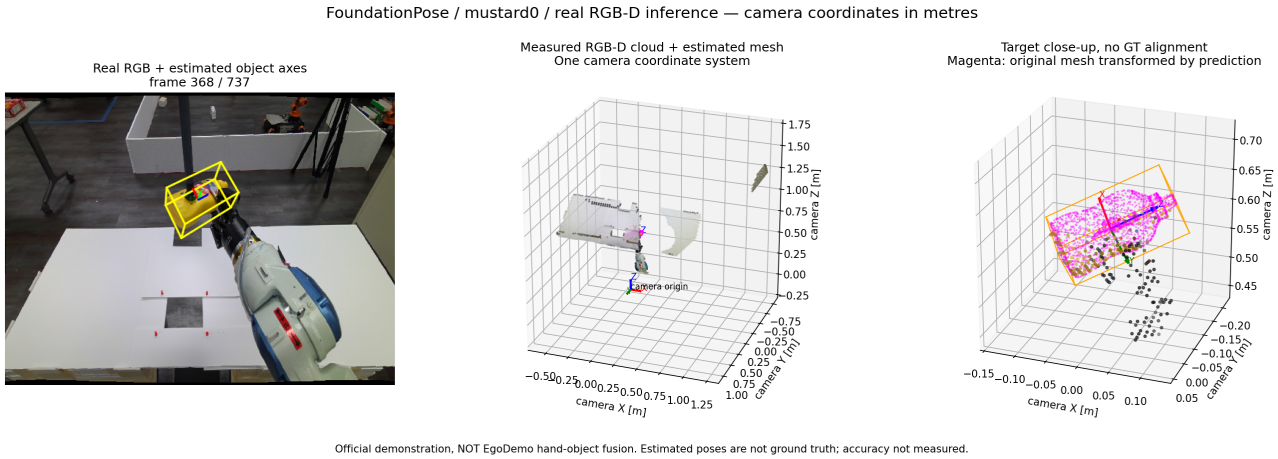


图 6 FoundationPose 独立后端验证：RGB 叠加、真实深度反投影点云及预测 mesh 局部图。紫色 mesh 由估计位姿变换，不按 GT 重新对齐。这个 737 帧公开样例包含机械臂，仅用于说明 6D 后端与三维坐标计算；真人手物演示见图4，第一视角分支的表示原理见图3和图8.

5.3 EgoDemo 双目重建与无 CAD 几何分支

第一视角物体通常没有逐个可用的 CAD 模型，实际工程使用同采集双目、实例表面种子和跨帧点对应来构建局部参考系。相机相对变换为 $T_{lr} = T_{rw}^{-1} T_{lw}$。先检查标定与像素对应的一致性，再校正双目、估计视差并进行左右一致性筛选；校正后的理想情形满足 $Z = f_x b/d$，非校正情形用双投影矩阵三角化。来源中存在标定修正与留出像素检查，修正记录与原参数同时保留。

连续轨迹提供对应点 $\{a_j, b_j\}$，刚性估计求解

$$(R^*, t^*) = \arg \min_{R \in SO(3), t} \sum_{j \in \mathcal{I}} \|R a_j + t - b_j\|_2^2. \tag{4}$$

实现用 RANSAC 剔除错误对应，再对中心化协方差做 SVD 求 R, t。本地默认要求至少 8 个内点、内点比例至少 0.65、距离阈值 0.012 米；同时检查点云跨度与第二奇异值，避免近点状 / 线状目标的旋转不可观。另有稀疏参考点到后续图像的 PnP 分支，保留重投影残差与内点数。

物体局部原点来自初始可见表面，轴可由初始相机定义，未必等于 CAD 中心或语义轴。关联相同名字不代表坐标系已经对齐：跨 tracklet 拼接还需相对刚体变换和表面一致性证据。纸张、布料等非刚体保留点轨迹或局部表面参考系，铰接工具按部件表达；它们不强制拟合为整物体刚体。

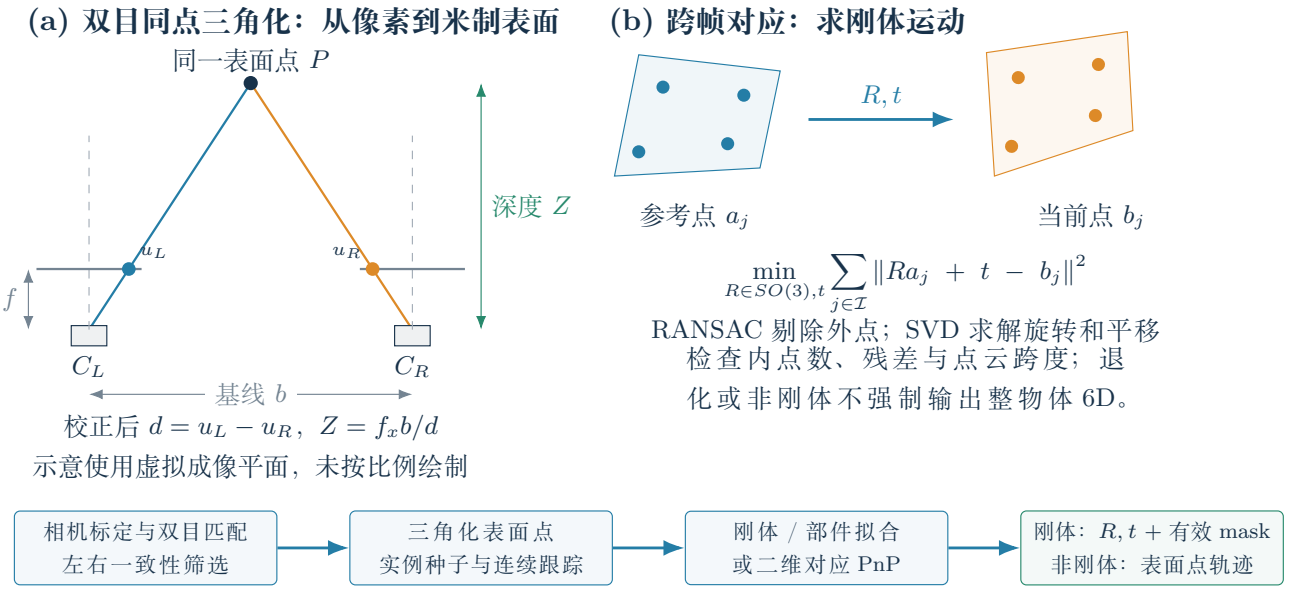


图 7　双目重建与跨帧刚体拟合原理图。左上：同一表面点由左右像素射线交会恢复深度，理想校正情形为 $Z = f_x b/d$。右上：参考帧与当前帧的对应点，经 RANSAC 筛选后用 SVD 求刚体变换。下：从标定、点匹配到局部几何输出的工程路径。相机和点集为原理示意，几何表示区别见图8。

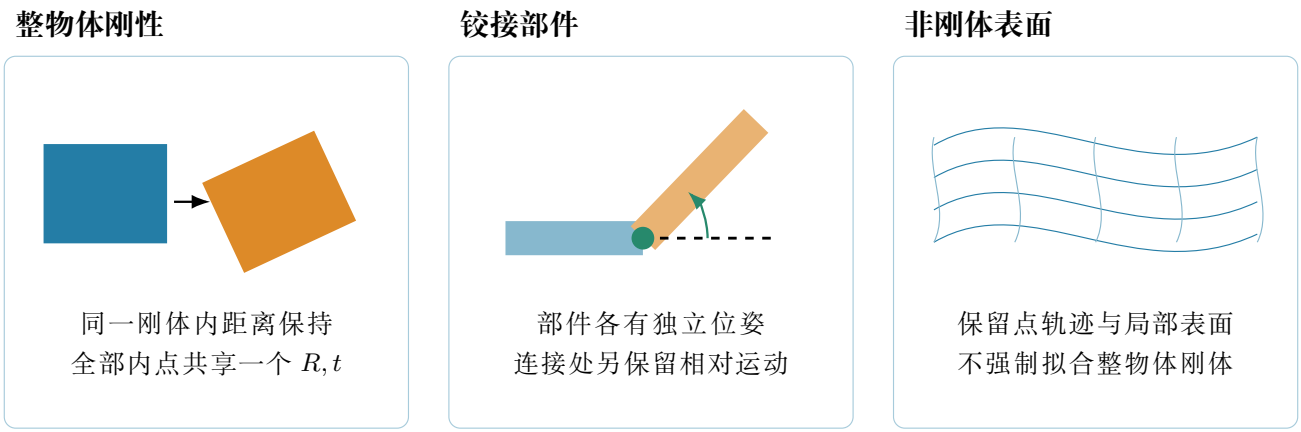


图 8　几何表示的三种情况：整物体刚性运动、铰接目标的部件运动和非刚体表面形变。点与形状为原理示意，不是实验数据或受限记录的重建。只有满足刚性约束且对应可靠时，才输出统一物体位姿。

6　感知模块的指标与验证图

6.1　按指标回答不同问题

感知验证按输入对齐、输出覆盖、几何一致性、运行时延和独立精度分别报告。覆盖率回答“有多少帧输出有效值”；几何一致性回答“变换、投影与文件是否自洽”；独立精度回答“与外部真值相差多少”。只有具备同物体、同帧、同坐标的独立参考，才能计算位置误差 $e_t = \|\hat{t} - t^*\|_2$ 及旋转误差

$$e_R = \arccos\left(\mathrm{clip}_{[-1,1]}\left(\frac{\mathrm{tr}(\hat{R}R^{*\mathsf{T}}) - 1}{2}\right)\right). \tag{5}$$

式中 clip 限制输入到 $[-1, 1]$；对称物体需按对称等价类定义评价。手部三维精度可用 MPJPE 或带阈值的 PCK，二维可用独立关键点重投影误差。现有感知材料没有提供完整独立精度评测，因此这些项写为未测，不用覆盖率或轨迹变化替代。

环节 / 验证集	已测结果	分母与范围	结果含义
EgoDemo 双手来源检查	双手同时有效 7146/7164	两采集合计 7164 帧	来源姿态覆盖，非检测精度
EgoDemo 标定像素复核	275 直接一致，20 修正后检查	300 采集；另 4 待复核、1 不一致	抽样像素一致性
FoundationPose 后端	737/737 有限合法刚体输出	独立公开 RGB-D 样例	运行覆盖与数值合法性
DexYCB 手物联合输出	44/44 右手与物体均有输出	同一 44 帧，三次复测	模块联调与短片覆盖
HO-Cap 多物体输出	446 帧；四物体各 446 有效	真人单采集；手任一有效 446 帧	多目标工程覆盖
感知独立位置 / 旋转 / 手精度	未测	独立参考尚未形成对应结果	不报告虚构准确率

表 1 感知验证结果与统计口径，来自既有运行 JSON / NPZ / CSV。不同数据集的计数不相加成为统一测试集。具体失败和缺失状态按各次运行保留，而非覆盖成一个总通过率。

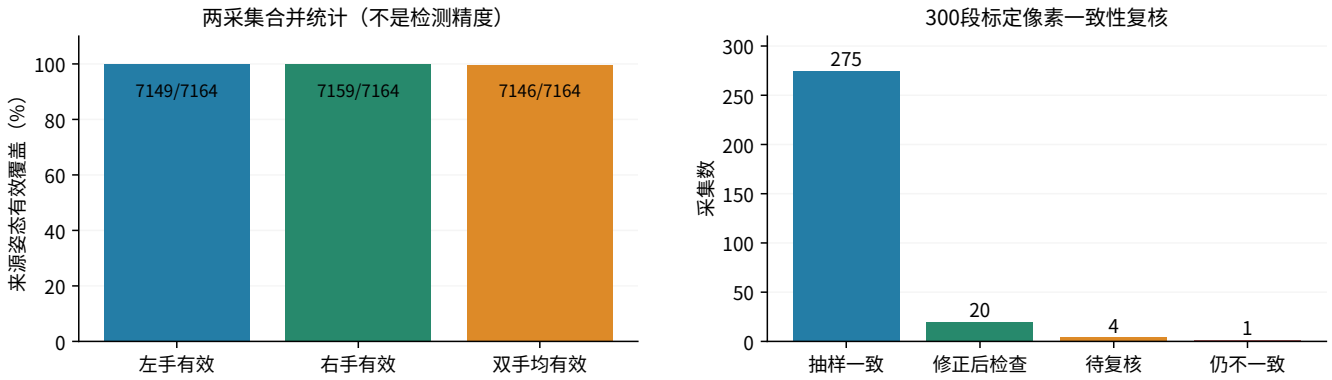


图 9 手部来源覆盖与相机像素一致性验证图。左侧为两采集合并的有效帧数与比例；右侧为 300 段重建流程最终汇总中的标定状态。两者分别验证数据可用性与几何输入，不是学习模型精度。

6.2 6D 数值验证与逐帧延迟

图10直接从 737 个保存位姿和 44 帧联合输出的 CSV 复算。旋转正交性最大元素偏差为 3.472×10^{-6}，$|\det R - 1|$ 最大约 1.594×10^{-6}；说明输出满足刚体矩阵数值约束。平移轨迹展示实际运动，不是相对于真值的误差曲线。

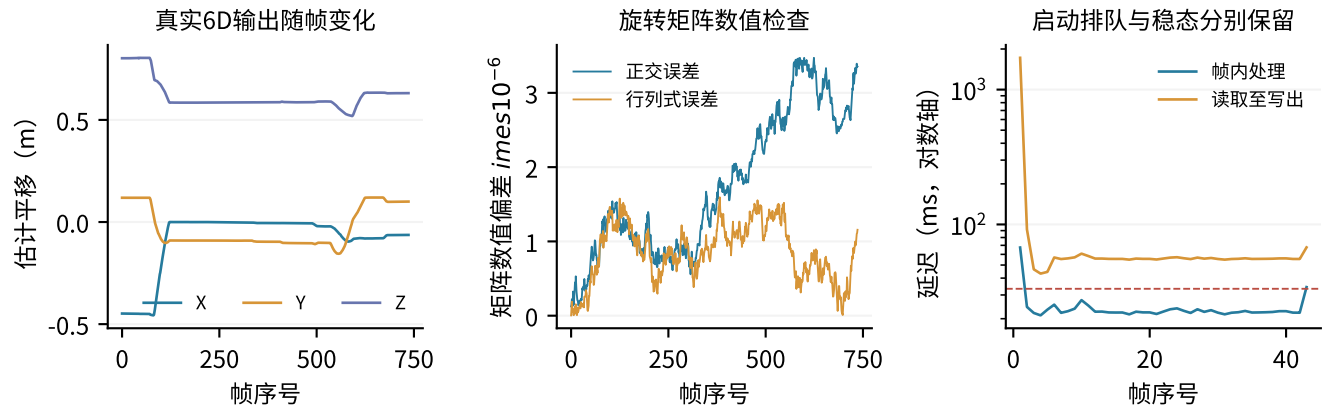


图 10 逐帧感知验证。左：6D 输出的平移变化；中：旋转正交性与行列式偏差；右：DexYCB 最终复测中除注册帧外的帧内处理和读取至写出时延。右图采用对数轴保留首个预取帧跨注册阶段的排队峰值，未裁掉慢帧。矩阵误差属于数值检查，不属于姿态真值误差。

6.3 感知性能优化与实际边界

同一 44 帧 DexYCB 片段在 L40 上比较不同手模型、物体跟踪迭代和输入预取。最终 lite 手模型、一次物体跟踪、CPU / GPU 同帧并行、有界预取的三次复测稳态处理能力为 41.409、41.471、41.524 FPS；帧内 P95 为 27.056、27.967、27.265ms。图11保留较慢配置，说明优化的实际变化。

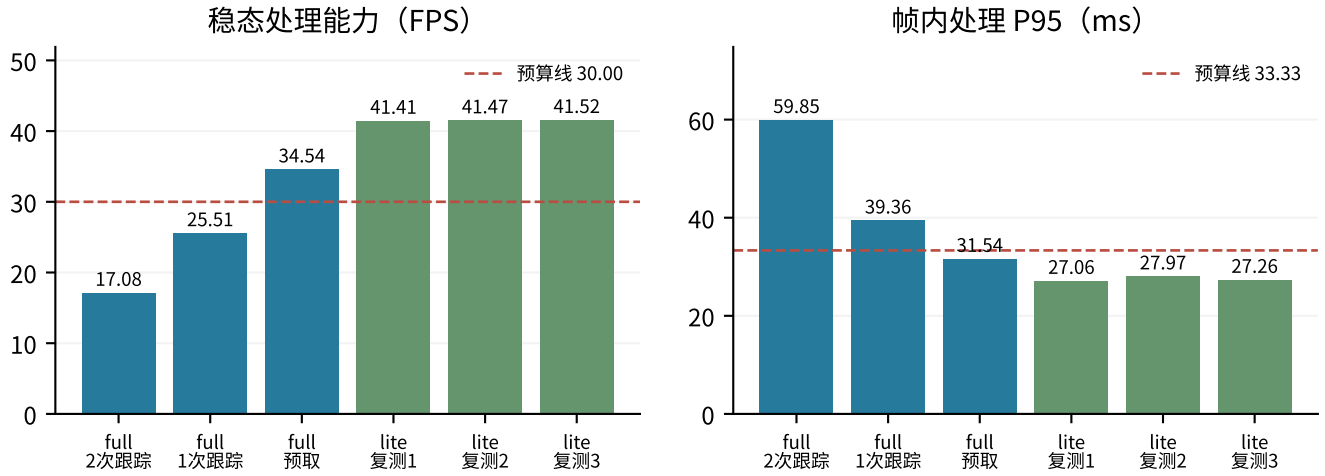


图 11 真实感知配置的吞吐与帧内 P95，均来自同一 44 帧片段，稳态分母为除注册帧外的 43 帧。虚线对应 30FPS 处理预算。改手模型和跟踪迭代数可能影响精度，图中只报告实测性能；三次复测不是 132 个独立样本。

最终三轮各有 2/43 帧超过 33.33ms，首帧注册约 1.63–1.66 秒，读取至写出 P95 为 55.49–66.90ms。因此可以报告短序列稳态处理能力，不能把 MP4 的 30FPS 或环路时延写成相机曝光到屏幕显示的硬实时指标。HO-Cap 四物体配置的稳态约 6.87FPS，单独记录其多物体计算量与输入条件，不套用单碗场景的速度。

7 数据构建与版本演进

7.1 原生时间轴与图监督

基础资源池包括 300 段采集、75 个原始任务和 868,255 帧。数据按采集保持原始划分，不把同一采集的不同机位或相邻重叠窗口当作独立视频。采样、审核和训练始终记录采集 ID、原生帧号、时间戳、数据版本与来源哈希。

窗口长为 32 帧，目标帧 u 与历史末帧 t 满足 $\tau_u - \tau_t \geq 1$ 秒，实际时间间隔依原生时间戳计算。实体集合包括左手、右手、双手组合和最多八个物体，共 $E \leq 11$ 个节点。输出为 $E \times E \times 66$ 的有向多标签关系图；66 表示冻结词表容量，实际具有监督的类型随发布版本统计。

标签分为操作、关系、转换与协作四层。状态类描述目标帧，转换类表示预测区间内完整包含的已确认事件范围。各单元保存正负值和有效掩码，未检查、遮挡或边界不确定的单元保持未知。未知不是负例，事件范围也不等于精确转换时刻。

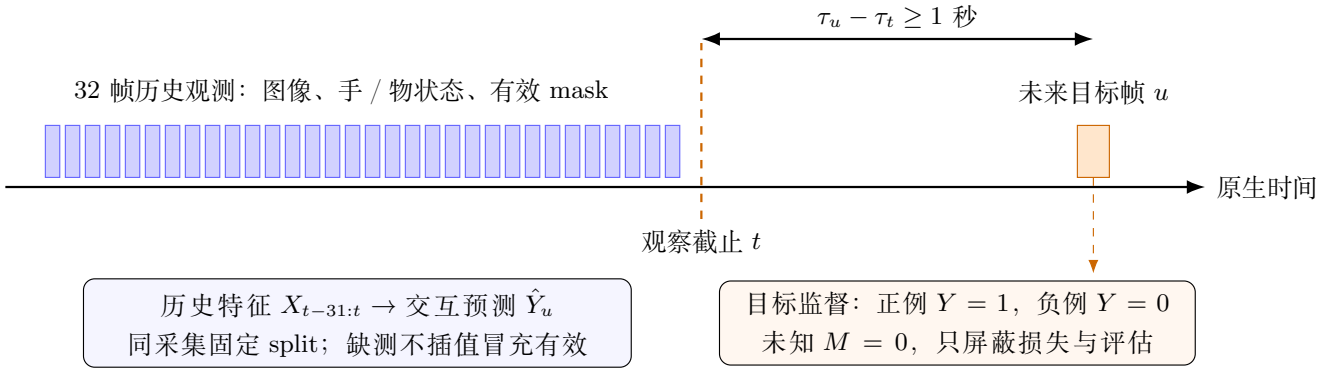


图 12 时序样本与监督边界示意。历史窗口只使用截止帧及此前的信息，目标由原生时间戳确定；图中方块为结构示意，间隔不表示原视频帧率。正 / 负 / 未知分别编码，未来标签不参与输入编码。

7.2 自动复核与冻结发布

后续自动化流程包括视觉种子、连续证据渲染、二维跟踪、联系表生成、视觉模型复核与标注组装。复核不仅检查正关系，也单独生成有可见证据的明确负例。接受 / 拒绝记录保留源图、原生范围、实体引用和判定来源，形成可供加载器验证的发布包。自动视觉复核产生的标签保留银标属性。

发布过程需要在同一冻结点固定索引、数组、标签和证据文件。流水线扩充与训练可以围绕不同版本并行，但冻结过程中继续改写同一证据集合会导致来源不一致。项目迭代曾修复索引导出遗漏、证据配置改变导致像素不一致，以及清理证据文件破坏审计依赖等问题。这些修复的意义在于保证“训练读取的是哪个版本”可被追溯。

阶段	可回溯规模或配置	主要变化	结果用途
初始 V5（10 月 24 日）	5 采集；592/366/280 窗	基础 120 维、有向图训练	历史联调结果
自动复核试点（10 月 25 日）	4 采集；461/69/114 窗	自动复核、负例与发布链	自动流程对照
扩展冻结 v4（10 月 26 日）	36/12/9 采集；5855/2123/1326 窗	多采集验证 / 测试、RSI 继续	已恢复评估输出
后续 v7（10 月 28 日）	42/19/13 采集；8049/3329/2757 窗	继续扩充，V6 位姿接入	已恢复索引摘要
后续 fasttrain（11 月 4 日）	36/7/10 有效采集；1012/159/172 窗	132 维、稀疏采样加速	独立采样版本
最终全量与多轮 RSI	项目方报告最终结果约 0.93	最终测试文件绑定待确认	正式结论的绑定目标

表 2 项目演进，斜杠依次为 train/val/test。不同数据版本的规模和采样策略不同，不能混为单一试验。fasttrain 有效采集数来自本次读取的索引。扩展 v4 的验证 / 测试窗口数已与服务器 benchmark 核对；同名数据根后续曾重新导出，历史运行不直接绑定其当前内容。

7.3 几何增强与覆盖解释

物体几何由二维观测逐步扩展为刚体 / 部件位姿、近似刚性集合和非刚体表面参考系。记录中的 v10 几何扩展使有位姿候选的采集由 162 段增加到 293 段，候选位姿帧由 274,791 增加到 699,913。该计数包括不同几何范围，反映候选覆盖，而非全部交互目标的独立 6D 精度。

后续位姿特征通过视觉实体到几何实体的名称关联接入。早期精确名称匹配漏掉“胶带 / 黄色胶带卷”等别名，随后加入别名拆分、子串与二元组匹配，提升部分场景的可用性。没有匹配证据的物体仍应保持缺失；非刚体也不能仅因提供一个局部参考系就被称为整物体刚体。

8 动态交互图预测方法

8.1 统一实体特征

基础版本的每个实体使用 120 维向量：归一化二维框四维、历史速度二维、框内 RGB 均值与标准差六维、手部二维关节 42 维、三维关节 63 维，以及有效性和种子标记三维。物体不具备的手关节字段置零，双手组合节点不伪造独立骨架。无效特征在进入可学习层前通过 V_t 清零，避免 NaN 经线性层污染梯度。三维手姿态统一到历史末帧左相机坐标系，长度单位为米。

节点类别编码仅区分左手、右手、双手与物体四种角色。所有物体共享同一类别嵌入，不加入槽位编号嵌入。基础模型不使用名称嵌入；后续位姿匹配模块会使用中文名称来关联几何，名称关联错误因而可能间接影响输入。目标标签不作为前向特征。

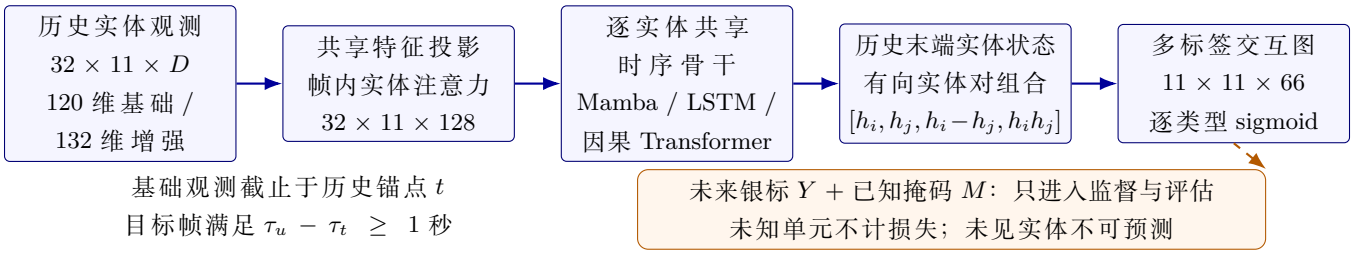


图 13 系统实现。帧内注意力建模空间上下文，时间骨干沿各实体历史独立且共享地运算；末端有向图头保留主体与客体的区别。同一数据版本内的三骨干对照替换时间模块；132 维位姿增强另记录离线来源。虚线表示损失与标签的关联，标签不进入前向特征。图为实现结构示意，不是实验输出。

8.2 帧内关系编码

以基础配置为例，首先用共享两层感知机将实体特征投影至 $d = 128$ 维，再加入实体类别嵌入。每帧的所有有效实体共同参与四头注意力：

$$Z_{s,i} = \phi(X_{s,i}) + e_{\kappa(i)}, \tag{6}$$

$$\widetilde{Z}_s = \mathrm{LN}\left[Z_s + \mathrm{Attn}(\mathrm{LN}(Z_s); V_s)\right]. \tag{7}$$

无效实体作为 key 被屏蔽，输出也重新置零。若整帧没有有效观测，实现暂时保留一个零值 key 防止全负无穷 softmax 产生 NaN，再屏蔽该帧所有输出。该步骤处理数值稳定性，不把缺失帧变为有效观测。

帧内注意力让手部节点能依赖附近物体的状态，同时使物体表示包含其他实体的上下文。这里的注意力权重不是物理接触标签，模型最终是否识别接触仍需由独立监督检验。

8.3 共享时间骨干

将张量由 $B \times W \times E \times d$ 重排为 $(BE) \times W \times d$，基础配置使用共享两层时间骨干建模每个实体的历史；RSI 候选的宽度和层数由其配置确定。在 Mamba 分支中，状态维数为 16，局部卷积宽度为 4，扩展倍率为 2。选择性状态更新可抽象写作

$$H_{s,i} = \overline{A}_{s,i} H_{s-1,i} + \overline{B}_{s,i} \widetilde{Z}_{s,i}, \tag{8}$$

$$O_{s,i} = C_{s,i} H_{s,i}, \tag{9}$$

其中与输入相关的系数选择保留哪些历史信息；实际计算使用现成的 `mamba_ssm` 实现。此式说明机制，并不省略后声称为完整软件层公式。

LSTM 分支采用相同宽度和层数的循环时间模块。Transformer 分支使用可学习时间位置编码、上三角因果屏蔽和四倍宽度的前馈层。三者共享实体编码器、图头、输入、标签与优化规则，但参数量不保证相等，因此本实验是接口和训练协议对齐的骨干比较，不是等参数量或等算力的严格对照。

历史中曾出现但在后续帧缺失的实体允许保留时间状态；从未出现的实体始终屏蔽。固定物体槽并不等于固定物理身份；只有在历史观察提供对应依据时，该节点才具备可解释的实体引用。

8.4 有向图解码与损失

在窗口末端提取实体状态 h_i，按有序实体对组合

$$r_{ij} = [h_i; h_j; h_i - h_j; h_i \odot h_j], \tag{10}$$

并通过共享感知机产生 K 个 logits ℓ_{ij}。顺序拼接和差向量保留方向性，使“手作用于物体”和“物体受到手作用”不会被自动视作同一边。每类独立 sigmoid 适用于多标签关系，不使用互斥 softmax。图头支持手到物体以及物体到物体的组合；下游解释仍须遵守类型语义，不能把任意高分组合都认作物理上有效的交互。

令 Q_{ij} 表示源和目标均在历史中出现。训练仅使用既有标注又满足预测条件的单元：

$$\mathcal{L} = \frac{1}{|\Omega|} \sum_{(i,j,k)\in\Omega} \mathrm{BCEWithLogits}(\ell_{ijk}, Y_{ijk}), \tag{11}$$

其中 $\Omega = \{(i,j,k) : M_{ijk} = 1,\ Q_{ij} = 1\}$。实现会拒绝指向历史未见实体的监督，而不是悄悄丢弃该项。未知单元不进入损失，FP32 累积 BCE 以降低混合精度误差；空监督 batch 必须显式跳过或报告，不能冒充有效训练。

物体槽位置换只改变节点排列；共享类别编码、帧内集合注意力、共享时间模块和共享实体对头使图预测随槽位相应置换。已有冒烟审计记录的最大绝对差为 1.788×10^{-7}。这证明特定检查下的实现一致性，不等于在任意身份错误下仍能正确预测。

8.5 132 维位姿增强与实体关联

后续 V6 将输入扩展为 $120 + 12 = 132$ 维。新增块依次为位置三维、旋转六维表示、位姿有效标记、离线候选标记和一维保留位。旋转编码为旋转矩阵的前两列；物体局部位姿经相机到世界变换对齐至世界坐标。无匹配或无效帧的块置零，并由有效标记区分，不用零位置冒充有效物体位置。

`PoseTable` 将视觉实体与 v10 几何轨迹关联：先保留并拆分原始名称中的别名，再进行归一化；匹配分数优先考虑名称相等，其次子串关系，最后字符二元组的 Jaccard 重叠。当前代码以 0.34 为最低接受分数。这是工程关联规则，可能把语义接近而物理上不同的实例匹配在一起，故报告和 demo 需保留关联置信与缺失状态。

v10 几何包含整物体、刚性部件、近似刚性集合与非刚体表面参考系。后两者能提供局部运动描述，但不能全部改称整物体刚体 6D。当前位姿块显式带有 `offline_pose_candidate` 标记，来源可能使用离线信息。因此 120 维历史观测实验与 132 维离线几何增强实验应分别报告；将块附到历史帧上，并不自动证明上游位姿估计本身因果。

9 RSI 自动迭代优化

9.1 候选生成与训练

RSI 将一次优化抽象为“当前配置 → 受约束变异 → 候选训练 → 验证评分 → 候选晋升”。每个候选保存独立目录和配置，避免后续轮次覆盖此前训练结果。现有实现支持切换 Mamba、LSTM 和 Transformer，并在白名单中修改网络宽度、层数、dropout、batch size、学习率、权重衰减及 checkpoint 选择指标。

配置项	本地 RSI 实现的搜索集合
隐藏维度	64、128、256
时间层数	1、2、3、4
dropout	0、0.1、0.2
batch size	8、16、32
学习率	10^{-4}、3×10^{-4}、10^{-3}
权重衰减	0、0.01、0.1
轮内选优	val loss / micro-F1 / macro-seen

表 3 搜索空间来自 `rsi_v5.py`。最终运行的候选集合以实际 history 与配置为准，不由默认参数推算完成轮数。

数据路径、输入语义和标签词表不属于这段随机变异的搜索对象。切换数据发布或 120 / 132 维特征时应开启有明确版本绑定的新系列，而不是把它解释成同一系列内的一次普通超参变异。RSI 可同时使用验证损失选择某个候选内部的 checkpoint，再使用验证 micro-F1 在候选之间比较；这两个选择层次应分别记录。

9.2 验证选择、失败处理与晋升

已检查实现的候选评分为验证 micro-F1，只有新分数超过当前分数的 1.02 倍时才晋升；该 2% 相对阈值是搜索启发式，不是统计显著性检验。训练退出非零、评估失败或缺少 benchmark 的候选记录为失败，不以零分或未完成结果冒充成功试验。搜索过程只调用 val，胜者的 test 评估在外部执行。

候选目录、`history.jsonl`、`score.json`、`genome.yaml` 与汇总报告共同保存实验谱系。历史有多个系列：`rsi_v5`、`rsi_auto` 和后续 `rsi_final`。不能将每个系列的默认八轮累加为实际成功轮数，也不能把失败后重跑的同一候选重复计算为新模型。最终需要报告总尝试数、唯一候选数、成功评分数、晋升序列及冠军配置。

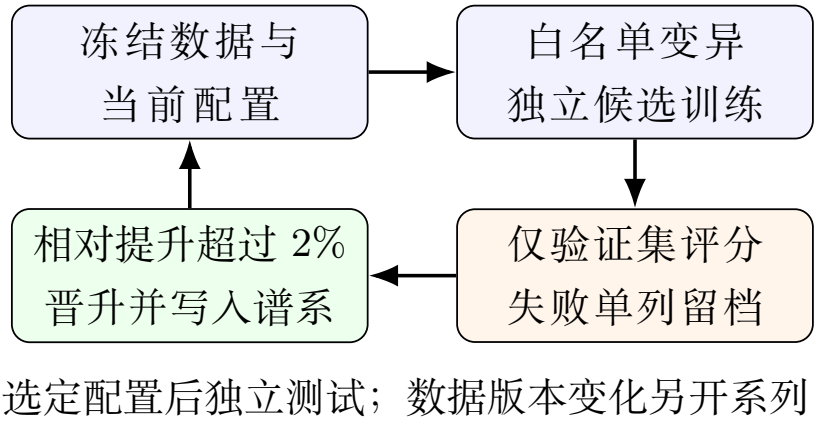


图 14 RSI 机制图。该图说明代码流程，不代表已完成轮数或各轮收益。

9.3 服务器账本与实际轮次

本次直接回收三个系列的 `history.jsonl`、`score.json`、配置与 benchmark。`rsi_v5` 和 `rsi_auto` 各有 8 条轮次记录、6 个唯一候选；`rsi_final` 有 30 条记录、21 个唯一已评分候选，另有一个候选目录尚无 score 文件。重复出现的候选复用既有评分，因此不能把 46 条记录称为 46 个独立模型，也不将当前无 score 的目录算作成功实验。

系列	记录数	唯一已评分	最高 val F1
rsi_v5	8	6	0.856580
rsi_auto	8	6	0.914068
rsi_final	30	21	1.000000

表 4 服务器快照中的 RSI 账本，三个系列对应不同数据版本。表中最高分不必等于当前 genome，是否晋升还受 2% 相对阈值约束。

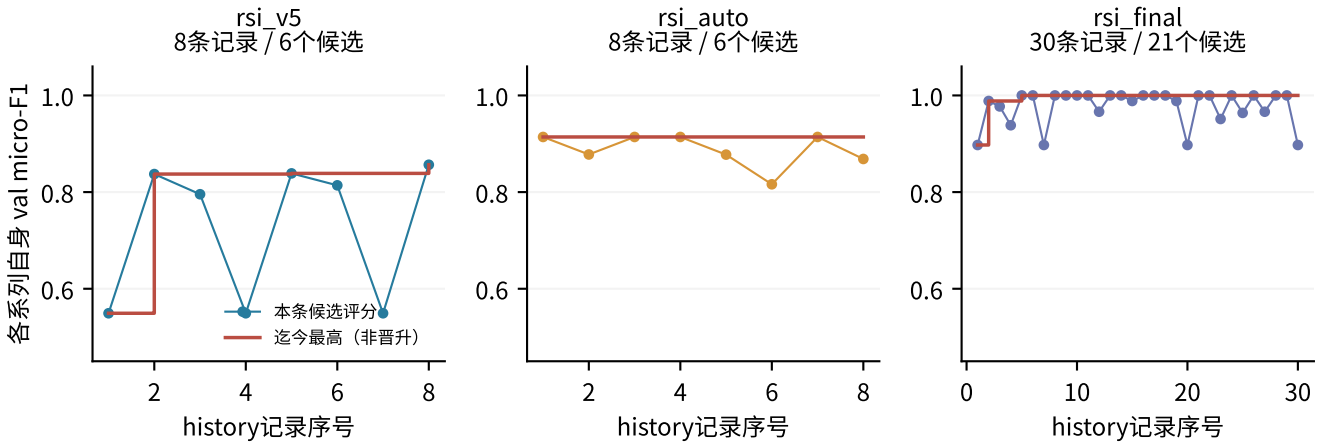


图 15 由三个实际 history 逐条复算的 RSI 曲线。横轴为账本记录序号，保留重复候选复用；红线为迄今最高分，不冒充晋升记录。各系列的验证集不同，分面展示而不连接为同一测试集上的提升。

后续 `rsi_final` 使用 132 维输入、fasttrain 数据、80 个 epoch 上限及验证 micro-F1 选优。当前 genome 为两层 64 维 LSTM、batch size 16、学习率 3×10^{-4}、权重衰减 0.01；其保存的验证 F1 为 0.988506。存在 1.0 候选，但从 0.988506 到 1.0 不足 2% 相对提升，不能仅按最高候选值认定 genome 已经晋升。

这一验证集为 159 窗口、275 个已知单元，含 43 个接触正例与 232 个抓持负例。1.0 仅表示该监督分布上的验证得分，不表示 66 种交互均得到验证，更不能替代最终独立测试。当前三个 `*_final` 目录保存了模型和配置，但未发现对应 test benchmark；保留项目方最终约 0.93 声明，后续应与指定最终运行绑定。

10 实验结果与版本对应

10.1 已恢复的扩展数据评估

表5已直接核对服务器 `graph_v5_auto/*_auto_v4/eval/`中的评估 JSON；与历史工具输出一致。该输出属于扩展冻结数据阶段，已不再是五段试点。LSTM 和 Transformer 的 test micro-F1 为 0.939，Mamba 为 0.905；验证 F1 分别为 0.816、0.872 和 0.807。

	验证集			测试集				
模型	BCE	micro-F1	Precision	BCE	Precision	Recall	micro-F1	macro-seen
Mamba	0.436	0.807	0.873	0.352	0.889	0.922	0.905	0.907
LSTM	0.491	0.816	0.856	0.297	0.885	1.000	0.939	0.943
Transformer	0.421	0.872	0.849	0.318	0.885	1.000	0.939	0.943

表 5 扩展冻结阶段的已记录评估值。数值已从服务器评估 JSON 核对，非本轮重新训练；表格显示三位小数。LSTM / Transformer 精确 test micro-F1 为 0.9388532001，Mamba 为 0.9052002986；测试 1326 窗口。该阶段采用 120 维输入，不冒充 132 维 RSI 的独立测试。

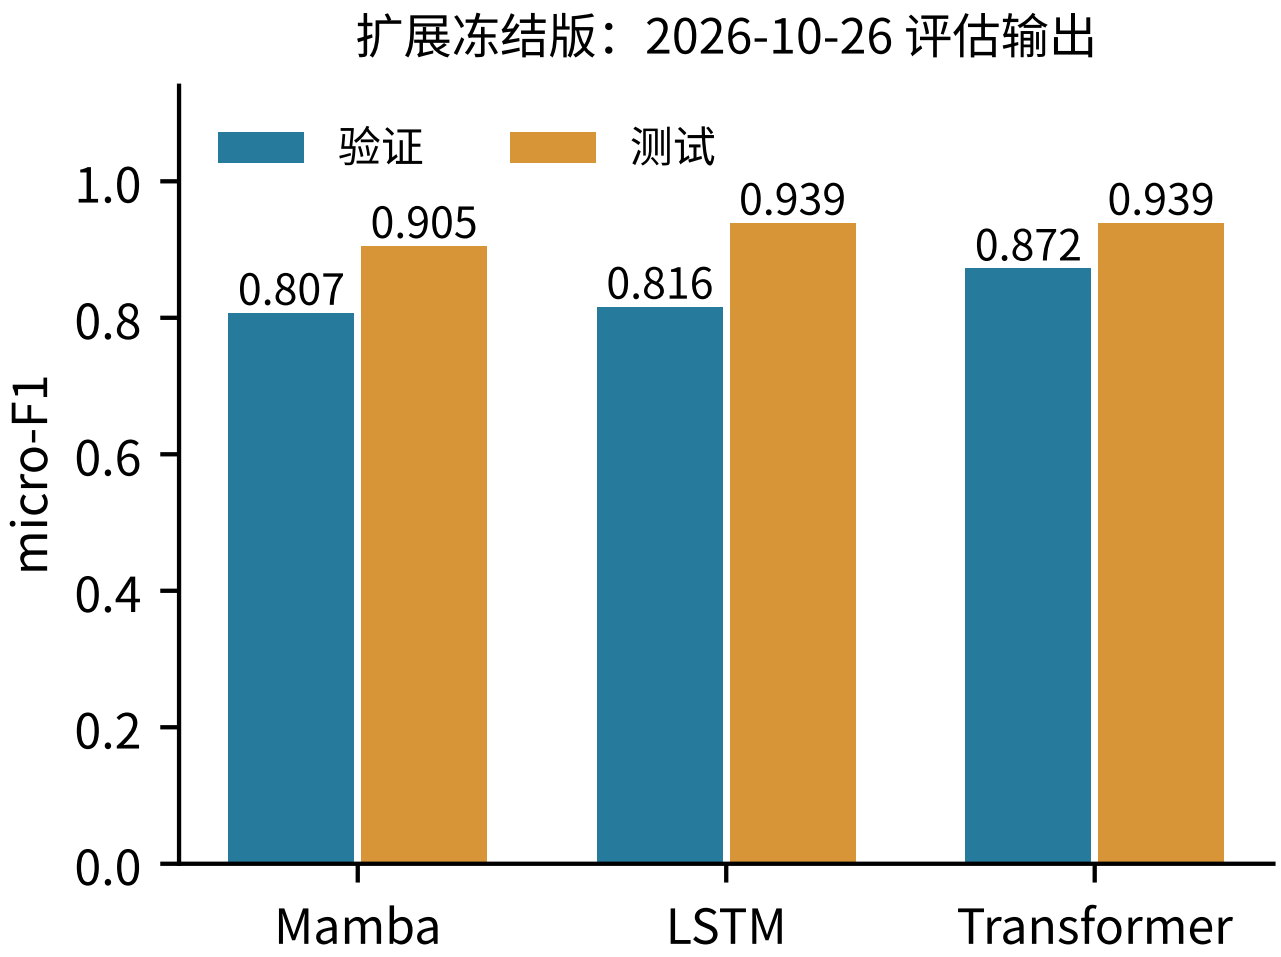


图 16 扩展冻结版本的验证 / 测试 micro-F1。不同骨干处于同一记录阶段；未提供重复运行方差，故不绘制误差条。

上述成绩支持系统在扩展数据阶段已经达到约 0.94 的测试 F1。LSTM 与 Transformer 的聚合 P/R/F1 相同，并不意味着它们对每个窗口的预测完全相同；需要逐单元输出才能比较错误分布。Mamba 在该阶段的测试 F1 低 3.4 个百分点，而 RSI 的搜索空间包含骨干选择，因此应以最终胜者的实际配置描述交付模型，不能预先假定冠军一定是 Mamba。

10.2 最终全量结果与后续 132 维实验

项目方确认最终全量结果约为 0.93，并经过多轮 RSI 优化。本次已直接读取后续训练配置和 30 条 RSI 记录，确认 132 维特征与多轮搜索实际存在。服务器保存的扩展阶段精确测试结果为 0.9388532001，包含 TP=3946、FP=514、FN=0；这是可直接核验的一项约 0.93 结果。

与此同时，后续 fasttrain 发布的有效窗口为 1012/159/172，对应有效采集 36/7/10；其 RSI 账本是验证评分，未附最终独立测试文件。本文因此同时保留项目方最终声明、扩展阶段原始测试和后续 RSI 验证三类记录，不仅凭数值接近、目录名或较高 val 分数认定它们是同一次实验。最终冠军指定后，应在相应索引和 checkpoint 下补齐主结果的唯一绑定。

10.3 不同版本之间的比较原则

图17展示系统开发中的分阶段成绩。随着自动复核、数据扩充和训练配置变化，三个骨干的历史 test F1 均发生变化。由于测试采集、标注分布和输入条件并不固定，不能把柱值差分解释为 RSI 的纯粹因果增益。RSI 收益应比较同一冻结数据、同一特征和同一评估口径下的初始配置与冠军。

全正预测的参照值依赖当前已知正负单元数，$F_1^{all+} = 2P/(2P+N)$。初始五段子集的参照只适用于该子集，不能拿来与扩展版或最终全量 0.93 比较。正式报告应从最终 benchmark 重新读取 TP/FP/FN 及标签支持数，再计算同口径参照。

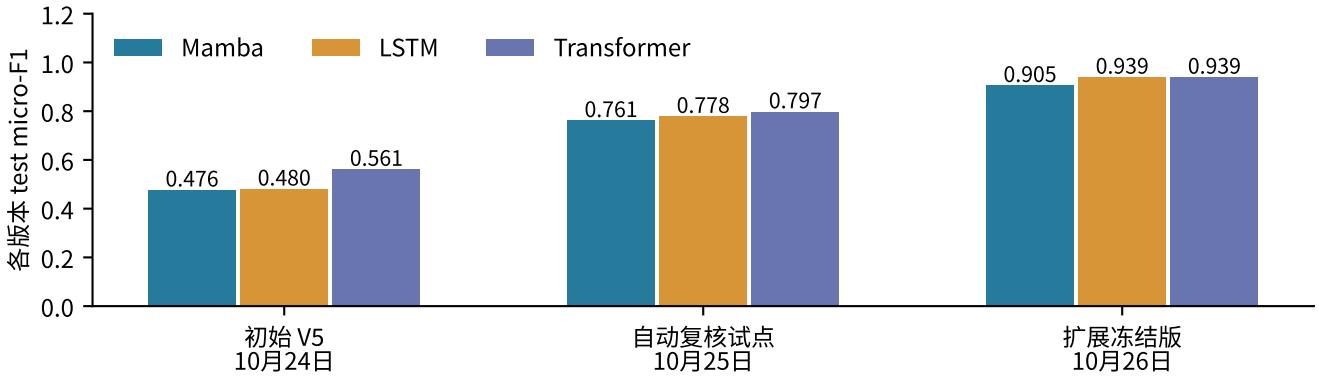


图 17 历史版本结果概览。每组柱对应各版本自身测试集，数据规模与监督发生变化，仅呈现项目演进，不作为固定测试集上的提升曲线，也不将最终 0.93 强行接到某个历史模型上。

11 完整流程的连续 Demo 与可视化

11.1 同一视频上的真实输出

2026 年 11 月 13 日新增连续三栏演示：左栏在 HO-Cap 原始 RGB 上标出红盖圆瓶、蓝色纸盒、椭圆罐、粉色包装盒，并显示实物缩略图；中栏为同帧 MediaPipe 手部与 FoundationPose 四物体 6D，以及视觉复核的当前交互阶段；右栏为现有 LSTM 权重产生的“主体—关系—客体”候选及概率。446 帧全部连续显示；前 31 帧积累历史，随后 415 帧有实际推理结果。原始视频、感知结果和模型输出按同一帧号对齐，图18为实际导出帧。



图 18 新增完整流程的真实演示帧。原始 RGB、手部与四物体 6D、关系预测并列显示；物体名称与颜色贯穿画面、缩略图与关系客体。中栏显示“手—持握 / 移动 / 松手—红盖圆瓶”的视觉复核阶段提示，过渡边界明确标为待核验，不作为逐帧真值。右栏显示左手到各物体的接触候选与概率，下方为全部 66 种类型中手到物体概率最高的五项。本图是 HO-Cap 跨数据集接口演示，不属于约 0.93 结果的测试集。

直接播放： https://egodata-full-pipeline-demo.miracle-techlink.chatgpt.site。页面提供完整流程、真人手物联合与四物体 6D 三段实际视频，可慢放、跳转关键帧并下载 MP4；PDF 中保留关键帧，连续动态内容由播放页呈现。

11.2 输入、模型与评价边界

此演示使用 `lstm_final` 已保存的第 43 轮 checkpoint，输入 132 维、历史 32 帧，展示阈值为 0.50；没有训练或调参。物体框由已估计 6D 位姿投影 mesh 包围盒得到，颜色统计取同帧 RGB；物体位姿使用相机坐标。手部仅有二维骨架，未将深度表面点当作度量关节三维，相关特征保持缺失掩码。完整 checkpoint 哈希和输入说明见播放页的演示清单。跨源输入下可见多条接触和共同运动关系的概率接近 1；展示保留原始输出，高置信度不代表正确，不能用画面直接证明泛化。

该片段无交互真值，源时戳仍未核验。演示回放及速度特征采用明确的 30Hz 假设，不宣称验证了未来 1 秒预测、实时速度或此片段的 F1。它用于检查各模块的贯通与真实输出，不能替代原 EgoDemo 实验，也不把 `lstm_final` 文件名等同于最终 RSI 冠军。阶段测试与项目方最终全量约 0.93 的结果仍按前文来源分别报告。



图 19 同一连续演示的第 100、223、379 帧。三栏分别对应原始画面、感知叠加与实际模型输出；可在播放页跳转到这些帧附近，检查物体移动、骨架与关系输出随时间的变化。该序列没有复核真值，画面不标注预测正确率。

11.3 原始交互演示与补充感知片段

授权工作区另保留既有 EgoDemo 三栏交互预测及手部世界 / 相机坐标视频，并提供本地统一播放页。这些原始记录按上游许可不再托管到公开站点。既有三栏演示的显示阈值为 0.80，与本次演示及 benchmark 常用的 0.50 分开记录。真人手物联合的 DexYCB 视频包含 44 帧；HO-Cap 四物体感知视频包含 446 帧，两者已加入公开播放页，并保留来源许可。ModelScope 当前仍为预留入口，尚无已上传数据文件。

12 复现与分析要求

最终报告需统一四项版本绑定：数据索引与准入文件、特征版本、模型配置 / checkpoint、评估器和指标口径。最终全量数据规模应从绑定索引统计，不将资源池、参与处理的采集数和产生有效监督的采集数混为同一数量。

132 维增强的上游物体几何包含离线候选，因此在对外说明时应区分条件化预测与严格在线预测。若需要论证全自动实时使用，应单独评价感知误差、身份切换、别名匹配失败及端到端延迟；现有三栏回放不等于实时传感器系统。该边界不改变已完成的交互预测实验，而是明确其使用条件。

对于优化归因，应保留同版本初始配置、冠军配置和每次晋升的验证分数，再独立报告测试结果。最终轮数、成功候选数和数据扩充效果不能根据默认参数或目录名称推断。已有失败候选也应保留，避免搜索账本只剩最终成功项。

13 结论

本项目已形成从第一视角数据、视觉复核、手物特征到有向交互图预测的完整技术链。本文补齐了手部与 6D 位姿原理、真实感知演示及可复算指标图，并在数据扩充、132 维位姿增强与多系列 RSI 中持续优化。项目方报告最终全量结果约 0.93；已恢复的扩展阶段原始评估记录显示 test micro-F1 达到 0.939。系统还完成了多版三栏关系图 demo。本次还直接回收了三个 RSI 系列的实际账本和阶段评估，并新增带实际模型输出的 HO-Cap 连续流程演示与视频播放页。后续定稿重点是将指定最终冠军的独立测试与其数据索引绑定，并用同一模型生成正式展示素材。

参考文献

[1] Dima Damen, Hazel Doughty, Giovanni Maria Farinella, Antonino Furnari, Evangelos Kazakos, Jian Ma, Davide Moltisanti, Jonathan Munro, Toby Perrett, Will Price, and Michael Wray. Rescaling egocentric vision. *International Journal of Computer Vision*, 2022.

[2] Kristen Grauman, Andrew Westbury, Eugene Byrne, Zachary Chavis, Antonino Furnari, Rohit Girdhar, et al. Ego4d: Around the world in 3,000 hours of egocentric video. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022.

[3] Albert Gu and Tri Dao. Mamba: Linear-time sequence modeling with selective state spaces. *arXiv preprint arXiv:2312.00752*, 2023.

[4] Lightwheel AI. Egodemo dataset. https://huggingface.co/datasets/LightwheelAI/EgoDemo. Accessed 2026-11-12; source data and derived releases are versioned locally.

[5] Bowen Wen, Wei Yang, Jan Kautz, and Stan Birchfield. Foundationpose: Unified 6d pose estimation and tracking of novel objects. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.

[6] Fan Zhang, Valentin Bazarevsky, Andrey Vakunov, Andrei Tkachenka, George Sung, Chuo-Ling Chang, and Matthias Grundmann. Mediapipe hands: On-device real-time hand tracking. *arXiv preprint arXiv:2006.10214*, 2020.

A 公开入口与数据状态

- 代码仓库：https://github.com/miracle-techlink/egodata_process。
- 报告发布页：https://github.com/miracle-techlink/egodata_process/releases/tag/technical-report-2026-11-12。
- ModelScope 数据集：https://www.modelscope.cn/datasets/Liuyue9698/ego_pose_dataset。2026 年 11 月 12 日直接读取 master 文件树，只发现 README 与 Git 属性文件，尚无数据文件；该地址当前是预留入口。
- EgoDemo 上游入口：https://huggingface.co/datasets/LightwheelAI/EgoDemo。受限原始材料由上游授权渠道提供。

B 图像来源、署名与公开版范围

本报告是项目技术研究说明。手部坐标与表面运动的公开版替代图为独立绘制的原理示意。新增交互界面与连续关键帧来自真实 HO-Cap 观测和 LSTM 推理，属于跨数据集流程演示，并非原 EgoDemo 测试视频。聚合结果保持相应数据版本，未重新训练或改变模型成绩。

DexYCB 演示图：来源为 DexYCB，作者 Yu-Wei Chao、Wei Yang、Yu Xiang、Pavlo Molchanov、Ankur Handa、Jonathan Tremblay、Yashraj S. Narang、Karl Van Wyk、Umar Iqbal、Stan Birchfield、Jan Kautz 和 Dieter Fox。数据采用 CC BY-NC 4.0，https://dex-ycb.github.io/；许可https://creativecommons.org/licenses/by-nc/4.0/。本报告作非商业研究展示，添加了项目估计的手部骨架、物体框与姿态轴，原数据权利保留。

HO-Cap 演示图：来源为 HO-Cap，作者 Jikai Wang、Qifan Zhang、Yu-Wei Chao、Bowen Wen、Xiaohu Guo 和 Yu Xiang。数据采用 CC BY 4.0，https://irvlutd.github.io/HOCap/；许可https://creativecommons.org/licenses/by/4.0/。本报告选取已有推理渲染帧并添加物体估计叠加，不暗示作者背书，不分发 MANO 基础模型。

FoundationPose 后端示例：使用 NVlabs/FoundationPose 官方公开测试输入与项目推理输出，加入估计框、轴、深度点云及预测 mesh 视图。来源https://github.com/NVlabs/FoundationPose，代码许可与原版权声明见其 LICENSE。示例用于研究与评估，未分发模型权重或底层数据包。

C 复现和仍需补充的验证

报告公式、结构图和聚合统计提供方法与实验口径；真实数据按各上游来源获取。原始索引、逐窗口输出、训练配置和 checkpoint 在对应授权工作区绑定，不随公开报告再托管。GitHub 主分支表示当前已公开实现，不能将工作区全部后续实验能力自动归入某个历史代码提交。

感知仍需对应独立参考的手部误差、物体平移 / 旋转误差及身份切换统计；覆盖、矩阵自洽和时延分别报告。项目方最终约 0.93、扩展阶段可核验的 0.938853 与后续 RSI 验证成绩仍按原有范围区分，指定最终运行的独立测试绑定尚需明确。